



UNIVERSIDADE D COIMBRA

Fundamentos de Inteligência Artificial
2025/2026 - 2º Semestre

Trabalho Prático N°2:
Lunar Lander
Uma abordagem reactiva

Trabalho realizado por:
Bernardo Direito, 2023215454,
uc2023215454@student.uc.pt;
Manel Carvalho, 2023212301,
uc2023212301@student.uc.pt;
Gonçalo Costa,
PL1

1. Introdução

O ambiente *Lunar Lander* é uma simulação bidimensional clássica utilizada para desenvolver e testar métodos de Inteligência Artificial. Enquanto num trabalho anterior o objetivo passou pela modelação de um agente reativo, o presente projeto visa o desenvolvimento de uma abordagem de neuroevolução para aterrar a nave de forma segura.

O agente é controlado por uma rede neuronal que recebe um vetor de 8 números reais (espaço de observações do estado da nave) e devolve um vetor com duas ações contínuas para controlar o motor principal e os motores secundários. O sucesso de uma aterragem dita que a nave termine entre as duas bandeiras da base, com as duas pernas no solo, velocidade controlada e orientação reta.

Este relatório detalha a modelação, implementação e análise do nosso Algoritmo Evolucionário, com um foco particular na distinção essencial entre o cenário idealizado (sem vento) e o cenário adverso (com vento).

2. Cenário Sem Vento: Evolução e Metodologia

Ao longo do desenvolvimento para o cenário sem vento, o projeto evoluiu iterativamente de uma versão inicial simples para uma configuração mais robusta e controlada. Este processo de melhoria contínua foi fortemente guiado pela análise constante das estatísticas extraídas em cada geração, bem como pela observação atenta da visualização gráfica do *Lunar Lander*, que nos permitiu diagnosticar visualmente as falhas de comportamento da nave.

2.1. Otimização da Função de Avaliação (*Fitness*)

A primeira fase do projeto consistiu em executar o algoritmo base de neuroevolução. A visualização das simulações e as estatísticas mostraram que a nave falhava frequentemente por três motivos principais:

- Aterrava fora da plataforma;
- Caía com demasiada velocidade vertical;
- Raramente terminava com ambas as "pernas" em contacto com o solo.
- Nave com velocidade horizontal no sentido errado, ou seja, x e v_x com o mesmo sinal;

Tornou-se evidente que não bastava tentar maximizar a aptidão (*fitness*) de forma cega; era fundamental orientar a função de avaliação para recompensar aproximações intrinsecamente mais estáveis.

Numa segunda fase, refinámos substancialmente a função de *fitness*. Adicionámos penalizações explícitas para o desvio horizontal, velocidade horizontal excessiva,

velocidade vertical negativa elevada, inclinação da nave e velocidade angular. Em simultâneo, introduzimos recompensas progressivas para a proximidade à plataforma, manutenção de baixas velocidades, boa orientação e, criticamente, o contacto das pernas com o solo.

Para evitar premiar trajetórias que pareciam adequadas apenas no exato momento do impacto, passámos a considerar os estados recentes (incluindo o penúltimo estado antes do fim do episódio). Esta alteração foi decisiva para direcionar o treino para aterragens efetivamente seguras e consistentes. O compromisso, no entanto, é que este *fitness* tornou-se mais artificial e descolado da *reward* original fornecida pela framework *Gymnasium*, o que poderia levar alguns indivíduos a otimizar a nossa função sem generalizar perfeitamente para o problema base.

2.2. Robustez na Avaliação dos Indivíduos

Para colmatar os problemas de generalização, a mecânica de avaliação foi alterada. Em vez de avaliar cada indivíduo da população num único episódio, adotámos uma validação baseada em múltiplos episódios. A aptidão final de um indivíduo passou a contabilizar a média de *fitness*, a taxa de sucesso global e uma penalização associada ao desvio padrão.

Embora esta mudança tenha tornado o treino significativamente mais pesado do ponto de vista computacional — exigindo a orquestração de múltiplos processos —, reduziu drasticamente o fator "sorte". Controladores que aterravam perfeitamente apenas devido a uma *seed* inicial favorável deixaram de ser selecionados pela evolução.

3. Análise Experimental (Cenário Sem Vento)


A avaliação da nossa abordagem foi feita seguindo a tabela de 8 experiências proposta, variando taxas de mutação, *crossover* e a utilização (ou não) de elitismo. O processo revelou duas realidades distintas ao longo do nosso desenvolvimento: uma fase inicial com problemas de adaptação (arquivada na pasta [plots](#)) e a versão final otimizada (arquivada em [plots_final_table](#)).

3.1. Primeiras Iterações: A Ilusão do Treino (Resultados [plots](#))

Durante as avaliações preliminares da primeira *run*, deparámo-nos com um fenómeno claro de *overfitting* aos episódios de treino.

1. **A Ilusão do Treino vs. A Realidade do Teste:** Os dados do ficheiro [test_summary.csv](#) revelaram que os melhores indivíduos terminavam o treino com pontuações altíssimas (entre 1400 e 2100 pontos).

Contudo, no teste final rigoroso, composto por 1000 episódios, essas pontuações caíam a pique, situando-se em médias negativas na casa dos -290 a -350 pontos.



2. **Taxa de Sucesso Estagnada:** Independentemente de usarmos muita mutação, pouco *crossover* ou muito elitismo, a taxa de sucesso demonstrava uma estagnação severa. Na quase totalidade das 40 simulações realizadas (8 experiências × 5 execuções independentes), a taxa de sucesso ancorou-se entre os 21% e os 24%, tendo a Experiência 8 chegado a registrar um mínimo de apenas 16%.







3.2. A Versão Final e Melhorada (Resultados `plots_final_table`)


Através da observação do ambiente e das afinações explicadas metodologicamente na Secção 2, atingimos resultados francamente superiores na bateria final de testes (`plots_final_table`). O gráfico da taxa de sucesso média por geração comprova que a reestruturação da configuração foi bem-sucedida.

Nesta versão final, as experiências começavam com taxas de sucesso baixinhas (15% a 23%), mas registavam uma aprendizagem consistente. Destacaram-se os seguintes resultados:

- **A Melhor Configuração (Experiência 2):** Utilizando mutação alta (0.05), *crossover* moderado (0.5) e sem elitismo (0), o algoritmo arrancou nos 15.3% e atingiu o seu pico de **65.3%** de taxa de sucesso na geração 100, fechando com uma média de ~61.2%. A mutação alta revelou-se crucial para impulsionar a exploração de novos (e melhores) controladores no espaço de procura.
- **O Impacto do Elitismo (Experiência 6):** Com os mesmos valores de mutação e *crossover* da Exp 2, mas introduzindo elitismo, o sucesso final estabilizou nos 49.3%, com um pico de **52.0%** na geração 80. Isto sugere que, embora o elitismo proteja boas soluções, pode também forçar uma convergência prematura e aumentar a dependência dos indivíduos encontrados nas primeiras gerações.
- **Limitações de Exploração (Experiências 1, 3, 5 e 7):** As experiências configuradas com taxa de mutação baixa (0.008) apresentaram as piores performances globais, variando o sucesso máximo entre apenas 24.7% e 28.0%. Ficou patente que este nível de mutação é exíguo para a complexidade do problema, impedindo a população de escapar de ótimos locais fracos.
- **Excesso de Recombinação (Experiência 4):** Apesar de usar uma mutação alta (0.05), a adoção de um *crossover* muito agressivo (0.9) sem o apoio do elitismo resultou numa taxa de sucesso fraca de apenas 26.0%. Esta taxa de recombinação acaba por destruir soluções promissoras de forma disruptiva antes que estas se consigam consolidar na população.







Em suma, conclui-se que para o cenário sem vento, a arquitetura vencedora assenta no equilíbrio entre uma perturbação forte (alta mutação) e uma conservação parcial das características ancestrais (*crossover* moderado), sendo o elitismo prescindível para atingir o pico absoluto de eficácia.

4. O Desafio Adverso: Cenário Com Vento

A segunda meta deste projeto exigiu a evolução de controladores capazes de lidar com um ambiente significativamente mais hostil, caracterizado pela presença de vento. Tal como esperado, a introdução desta força externa contínua tornou o problema substancialmente mais difícil, refletindo-se numa queda geral das taxas de sucesso face às melhores configurações do cenário sem vento.

O vento introduz uma perturbação lateral constante que obriga o controlador a corrigir a posição da nave a todo o momento durante a descida. Esta necessidade de manobra constante agrava a complexidade da tarefa, uma vez que a nave tem de dividir a sua "atenção" e o uso dos propulsores entre o alinhamento horizontal e a travagem vertical.

4.1. Análise de Falhas e o Impacto da Perturbação



As estatísticas recolhidas (através dos dados de `plots_wind` e `logs_wind`) revelam que as principais razões de falha mantiveram-se ligadas ao controlo horizontal e à velocidade vertical, mas com uma incidência muito maior. A percentagem de episódios que terminaram fora da plataforma de aterragem disparou para valores entre os 42% e os 62%.



Simultaneamente, a percentagem de falhas por queda demasiado rápida (excesso de velocidade vertical) situou-se entre os 38% e os 62%. Estes dados demonstram uma correlação clara: ao ser obrigada a gastar esforço a corrigir o desvio lateral causado pelo vento, a nave perde eficiência no controlo da sua descida, aumentando drasticamente a probabilidade de um impacto destrutivo com o solo.

4.2. Avaliação das Configurações Evolutivas

A análise das oito configurações testadas sob estas novas condições permitiu retirar conclusões vitais sobre o comportamento dos operadores genéticos num ambiente instável:

- **A Importância Vital da Mutação (Experiência 2):** A configuração que obteve a melhor taxa de sucesso média foi a Experiência 2, alcançando cerca de **41.8%**. Esta experiência caracteriza-se pelo uso de uma mutação alta (0.05), um *crossover* moderado (0.5) e ausência de elitismo. Num cenário com ruído e perturbações externas, a mutação elevada revela-se fundamental, pois garante a injeção contínua de diversidade na população, permitindo explorar soluções mais variadas e encontrar controladores com reflexos capazes de lidar com desvios laterais imprevisíveis.
- **Robustez e Qualidade Global (Experiência 6):** A Experiência 6 obteve um desempenho formidável, com uma taxa de sucesso muito próxima da anterior (**40.4%**). No entanto, destacou-se por apresentar o **melhor *fitness* médio global**, atingindo cerca de 257.1 pontos (em comparação com os 197.5 pontos da Experiência 2). Ao aliar uma mutação alta com a proteção do elitismo, esta configuração demonstrou ser extremamente robusta, produzindo controladores de alta qualidade geral, mesmo apresentando alguma variabilidade residual entre as diferentes execuções. O elitismo mostrou-se útil para preservar os melhores comportamentos adaptativos encontrados.
- **O Efeito Prejudicial da Recombinação Excessiva (Experiências 3, 4 e 7):** As configurações que utilizaram uma taxa de *crossover* alta (0.9) sofreram quebras drásticas de desempenho. A Experiência 3 obteve apenas 21.4% de sucesso, a Experiência 4 ficou-se pelos 22.2%, e a Experiência 7 registou um mínimo de 18.7%. Estes resultados indicam que, num ambiente instável, cruzar demasiadamente os indivíduos acaba por ser destrutivo, quebrando combinações de pesos (sinapses) que eram delicadas mas úteis. Fica provado que, para contornar o vento, é preferível explorar o espaço de procura através de mutação do que depender excessivamente do *crossover*.





5. Conclusão Final

A transição de um ambiente estático para um ambiente com vento evidenciou a necessidade de adaptação das estratégias evolutivas. Enquanto configurações conservadoras conseguem bons resultados em ambientes controlados, o cenário com vento penaliza severamente as abordagens com pouca capacidade de adaptação (baixa mutação) ou com excesso de instabilidade genética (*crossover* muito alto).

As melhores configurações (Experiência 2 e Experiência 6) provaram que a mutação alta é a chave para o sucesso perante perturbações imprevisíveis. O desafio do *Lunar Lander* sob condições adversas resume-se à capacidade da rede neuronal manter a nave centrada sobre a plataforma ao mesmo tempo que gere, de forma reativa, o acionamento do motor principal para evitar uma colisão fatal.